

**Detectarea Anomaliilor în Serii de Timp
Financiare utilizând un Ansamblu Hibrid:
SSA, Procese Stocastice și Învățare
Adaptivă**

Jalba Cosmin

2026

Cuprins

1	Introducere	2
1.1	Motivația și Contextul Problemei	2
1.2	Obiectivele Lucrării	2
1.3	Structura Tezei	3
2	Fundamente teoretice	4
2.1	Taxonomia Anomaliilor în Seriile de Timp	4
2.2	Singular Spectrum Analysis (SSA)	4
2.2.1	1. Imersiunea (Embedding)	5
2.2.2	2. Descompunerea Valorilor Singulare (SVD)	5
2.2.3	3. Gruparea (Grouping)	5
2.2.4	4. Reconstrucția (Diagonal Averaging)	6
2.3	Procesul Ornstein-Uhlenbeck (OU)	6
2.4	Modelul GARCH și Volatilitatea Condiționată	6
2.5	Metode bazate pe Semnătură (Pattern Matching)	7
2.5.1	Justificarea alegerii DTW față de metricile clasice	8
2.5.2	Formalizarea matematică a DTW	8
3	Arhitectura Sistemului Hibrid (Ensemble)	10
3.1	Pipeline-ul de Procesare	10
3.2	Justificarea Ponderilor în Cadrul Ansamblului	10
3.2.1	1. Pondere Bazală: GARCH ($w = 1.0$)	10
3.2.2	2. Pondere Intermediară: Ornstein-Uhlenbeck ($w = 1.5$)	11
3.2.3	3. Pondere Critică: Pattern Matching / DTW ($w = 2.5$)	11
3.2.4	Scorul Final de Anomalie	11
4	Studii de Caz și Rezultate	13
4.1	Setul de Date	13
4.2	Analiza Robustității pe Alte Clase de Active	13
4.3	Analiza Comparativă: Static vs Dinamic	14
5	Concluzii și Direcții Viitoare	15
5.1	Sinteza Contribuțiilor	15
5.2	Direcții Viitoare de Cercetare	15

Capitolul 1

Introducere

1.1 Motivația și Contextul Problemei

Piețele financiare moderne se caracterizează printr-o complexitate dinamică ridicată și prin incidența recurentă a evenimentelor extreme, denumite în literatura de specialitate drept "Black Swans" (Taleb, 2007). Această realitate empirică invalidează adesea premisele fundamentale ale metodelor tradiționale de analiză, care se bazează preponderent pe Ipoteza Piețelor Eficiente (EMH) și pe distribuția Gaussiană a randamentelor.

Consecința directă a acestor limitări este incapacitatea modelelor clasice de a detecta timpuriu schimbările de regim structural și de a cuantifica corect riscul în perioade de volatilitate extremă ("Fat Tails"). Prin urmare, apare necesitatea critică de a dezvolta sisteme robuste de detecție a anomaliilor, capabile să opereze independent de regimul de piață predominant (fie el de calm sau de criză) și să integreze multiple perspective analitice.

1.2 Obiectivele Lucrării

Prezenta lucrare își propune dezvoltarea și validarea unui sistem hibrid de detecție a anomaliilor în seriile de timp financiare, structurat pe următoarele obiective specifice:

- **Descompunerea spectrală și filtrarea semnalului (SSA):** Implementarea unui algoritm de *Singular Spectrum Analysis* (SSA) pentru extragerea trendului principal și eliminarea zgomotului stocastic. Această etapă urmărește izolarea componentelor cu energie dominantă din seria de prețuri, oferind o bază curată pentru analiza ulterioară.
- **Modelarea dinamicii de revenire la medie (Procese Ornstein-Uhlenbeck):** Utilizarea proceselor stocastice de tip Ornstein-Uhlenbeck pentru a modela comportamentul reziduurilor față de trendul identificat. Obiectivul este cuantificarea parametrilor fizici ai pieței, respectiv viteza de revenire la echilibru (θ) și mărimea șocurilor, permițând distingerea între fluctuațiile normale și anomaliile structurale.
- **Modelarea volatilității heteroscedastice (GARCH):** Integrarea modelelor de tip *Generalized Autoregressive Conditional Heteroscedasticity* (GARCH) pentru a surprinde natura variabilă în timp a riscului. Aceasta permite ajustarea dinamică

a pragurilor de detecție în funcție de regimul de volatilitate curent, reducând rata alarmelor false.

- **Dezvoltarea unui mecanism de decizie unificat (Ensemble Learning):** Construirea unui meta-algoritm de tip *Weighted Voting* care agregă semnalele statistice (SSA, GARCH, OU) cu o componentă de recunoaștere a formelor (*Pattern Matching*). Aceasta din urmă analizează similaritatea morfologică dintre comportamentul curent al pieței și semnăturile crizelor istorice (ex: Criza Financiară din 2008, Crash-ul COVID-19), oferind un scor de risc robust și multidimensional.

1.3 Structura Tezei

Lucrarea este structurată în 5 capitole, după cum urmează:

Capitolul 2 prezintă fundamentele teoretice ale metodelor utilizate, detaliind aparatul matematic din spatele analizei spectrale singulare și al proceselor stocastice. **Capitolul 3** descrie metodologia propusă și arhitectura pipeline-ului de procesare a datelor. **Capitolul 4** ilustrează rezultatele experimentale obținute pe indicele S&P 500, incluzând studii de caz comparative. În final, **Capitolul 5** sintetizează concluziile și propune direcții viitoare de cercetare.

Capitolul 2

Fundamente teoretice

2.1 Taxonomia Anomaliilor în Seriile de Timp

Conform clasificării standard propuse de Aggarwal [14], anomaliile într-un set de date pot fi categorisite în trei clase distincte. Sistemul hibrid propus în această lucrare este proiectat să adreseze fiecare tipologie în parte:


1. **Anomalii Punctuale (Point Outliers):** Un punct de date care deviază semnificativ de la restul distribuției. *În sistemul nostru, acestea sunt detectate de modulul GARCH (șocuri de volatilitate instantanee).*
2. **Anomalii Contextuale (Contextual Outliers):** Un punct de date care este considerat anomalie doar într-un anumit context (de exemplu, o scădere de preț care este normală într-o piață volatilă, dar anormală într-o piață stabilă). *Acestea sunt adresate prin filtrarea SSA și procesul Ornstein-Uhlenbeck, care definesc "contextul" (trendul și echilibrul) față de care se măsoară deviația.*
3. **Anomalii Colective (Collective Outliers):** O colecție de puncte de date care, luate individual, pot părea normale, dar care împreună formează un tipar neobișnuit (ex: o structură de crash). *Această clasă este detectată specific prin modulul de Pattern Matching (DTW), care analizează secvența morfologică a seriei de timp.*

2.2 Singular Spectrum Analysis (SSA)


Analiza Spectrală Singulară (SSA) este o tehnică non-parametrică de analiză a seriilor de timp, care combină elemente din statistica multivariată, teoria sistemelor dinamice și procesarea semnalului. Spre deosebire de Analiza Fourier (FFT), care presupune periodicități stricte și staționaritate, SSA este extrem de eficientă în extragerea semnalelor din serii financiare zgomotoase, scurte și non-staționare.

În cadrul acestui sistem, utilizăm SSA pentru etapa de pre-procesare: descompunerea prețului brut (P_t) într-o componentă de Trend determinist (T_t) și o componentă reziduală stocastică (R_t).

Algoritmul standard SSA constă în patru etape fundamentale:



(a) Analiza SSA (Trend)



(b) Analiza FFT (Trend+Zgomot)

Figura 2.1: Analiză Comparativă: Extragerea trendului / eliminarea zgomotului folosind SSA (a) si FFT (b)

2.2.1 1. Imersiunea (Embedding)

Transformăm seria unidimensională $X = (x_1, \dots, x_N)$ într-o secvență de vectori multidimensionali, construind **Matricea Traiectoriei X** (o matrice Hankel). Alegând o lungime a ferestrei L ($1 < L < N$), definim $K = N - L + 1$ vectori întârziți:

$$\mathbf{X} = [X_1 : \dots : X_K] = \begin{pmatrix} x_1 & x_2 & \dots & x_K \\ x_2 & x_3 & \dots & x_{K+1} \\ \vdots & \vdots & \ddots & \vdots \\ x_L & x_{L+1} & \dots & x_N \end{pmatrix} \quad (2.1)$$

Această matrice capturează dinamica sistemului în spațiu fazic.

2.2.2 2. Descompunerea Valorilor Singulare (SVD)

Calculăm matricea de covarianță $\mathbf{S} = \mathbf{X}\mathbf{X}^T$ și determinăm valorile proprii $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_L \geq 0$ și vectorii proprii ortonormați corespunzători $U_1, \dots, U_L$. Matricea traiectoriei poate fi reprezentată ca sumă de matrici elementare de rang 1:

$$\mathbf{X} = \sum_{i=1}^d \sqrt{\lambda_i} U_i V_i^T \quad (2.2)$$

unde $V_i = \mathbf{X}^T U_i / \sqrt{\lambda_i}$ sunt vectorii principali.

2.2.3 3. Gruparea (Grouping)

Aceasta este etapa de filtrare propriu-zisă. Împărțim setul indicilor $\{1, \dots, d\}$ în două submulțimi disjuncte: I_{trend} (componentele cu energie/valori proprii mari) și I_{noise} (componentele cu energie mică).

$$\mathbf{X}_{Trend} = \sum_{i \in I_{trend}} \sqrt{\lambda_i} U_i V_i^T \quad (2.3)$$

În analiza financiară, prima valoare proprie (λ_1) capturează de obicei peste 80% din varianța seriei, reprezentând trendul de piață general.

2.2.4 4. Reconstrucția (Diagonal Averaging)

Transformăm matricea rezultată $\mathbf{X}_{Trend}$ înapoi într-o serie de timp unidimensională prin mediere pe diagonalele secundare (procedura Hankelization). Rezultatul este seria de trend netezită, care va fi substrasă din prețul original pentru a obține reziduurile necesare analizei de risc.

2.3 Procesul Ornstein-Uhlenbeck (OU)

După eliminarea trendului prin SSA, componenta reziduală (R_t) prezintă un comportament oscilatoriu în jurul valorii zero, fapt confirmat de analiza spectrală (FFT), care indică o distribuție normală a zgomotului în jurul mediei zero. Pentru a modela matematic acest comportament și a stabili limitele "normale" de variație, utilizăm procesul stocastic Ornstein-Uhlenbeck.

Spre deosebire de Mișcarea Browniană standard (Wiener Process), care este non-staționară și are o varianță ce crește liniar cu timpul ($Var(W_t) = t$), procesul OU este *staționar* și prezintă proprietatea de **Revenire la Medie** (Mean Reversion). Aceasta îl face ideal pentru modelarea "zgomotului" pieței, care tinde să se corecteze după șocuri.

Dinamica procesului este descrisă de Ecuația Diferențială Stocastică (SDE) Langevin:

$$dR_t = \theta(\mu - R_t)dt + \sigma dW_t \quad (2.4)$$

Unde parametrii au o interpretare fizică directă în contextul pieței:

- μ : Media de echilibru pe termen lung (în cazul reziduurilor, $\mu \approx 0$).
- $\theta > 0$: **Viteza de revenire la medie**. Cu cât θ este mai mare, cu atât piața absoarbe șocurile mai rapid ("elastic rigid"). Un $\theta \rightarrow 0$ indică o piață ineficientă sau o schimbare de regim.
- σ : Volatilitatea intrinsecă a șocurilor aleatoare.

Soluția staționară a acestui proces implică o varianță de echilibru finită:

$$Var(R_t) = \frac{\sigma^2}{2\theta} \quad (2.5)$$

Această relație ne permite să definim un "**Tunel de Echilibru**" static. Orice deviație a reziduurilor care depășește intervalul $[\mu - 3\sqrt{\frac{\sigma^2}{2\theta}}, \mu + 3\sqrt{\frac{\sigma^2}{2\theta}}]$ este clasificată statistic ca o anomalie structurală, semnalând că forța de revenire a pieței a fost copleșită de magnitudinea șocului.

2.4 Modelul GARCH și Volatilitatea Condiționată

O limitare fundamentală a modelelor liniare (inclusiv a procesului OU cu σ constant) este asumarea homoscedasticității (varianță constantă în timp). Totuși, seriile financiare prezintă fenomenul de "*Volatility Clustering*" (Mandelbrot, 1963): perioadele de calmitate sunt urmate de perioade de calmitate, iar perioadele de turbulență tind să persiste.

Pentru a adapta pragurile de detecție la regimul curent de piață, utilizăm modelul **GARCH(p,q)** (Generalized Autoregressive Conditional Heteroscedasticity). Acesta modelează varianța curentă (σ_t^2) ca o funcție de erorile trecute și varianțele trecute.




Figura 2.2: Rezultatele analizei OU cu trendul identificat SSA pentru perioada 2018-2024.

Modelul specific utilizat în această lucrare este GARCH(1,1), care s-a dovedit empiric a fi cel mai robust pentru date financiare:

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2 \quad (2.6)$$

Unde:

- $\omega > 0$: Interceptul (varianța minimă de bază).
- ϵ_{t-1}^2 : Pătratul reziduului anterior (informația despre **șocul recent**). Parametrul α măsoară reactivitatea pieței la evenimente noi.
- σ_{t-1}^2 : Varianța estimată anterioară (informația despre **memoria pieței**). Parametrul β măsoară persistența volatilității.

Condiția de staționaritate impune ca $\alpha + \beta < 1$.

În arhitectura ansamblului propus, GARCH furnizează limitele **dinamice**. Spre deosebire de tunelul static OU, tunelul GARCH se "dilată" automat în perioade de criză. Astfel, o mișcare bruscă a prețului nu este etichetată imediat ca anomalie dacă ea apare într-un context deja volatil; este considerată anomalie doar dacă depășește volatilitatea (deja ridicată) anticipată de model.

2.5 Metode bazate pe Semnătură (Pattern Matching)

Metodele statistice descrise anterior (SSA, GARCH, OU) se concentrează pe proprietățile distribuției datelor (medie, varianță), ignorând adesea ordinea secvențială specifică a observațiilor. Totuși, crizele financiare tind să urmeze morfologii temporale distincte (o "semnătură" a comportamentului de panică), indiferent de anul în care se produc.

Pentru a detecta aceste structuri, utilizăm tehnica de *Template Matching* prin fereastră glisantă, având ca metrică de similaritate algoritmul **Dynamic Time Warping (DTW)**.




Figura 2.3: Analiza volatilitatii SP cu Garch pentru 2010-2024.

2.5.1 Justificarea alegerii DTW față de metricile clasice

În analiza seriilor de timp financiare, compararea directă a unei ferestre curente cu un șablon istoric (ex: Criza din 2008) întâmpină două obstacole majore:

1. **Diferența de Scară (Amplitudine):** Indicii bursieri cresc în timp. O scădere de 100 de puncte era enormă în 1990, dar este neglijabilă în 2024. Această problemă este rezolvată prin normalizarea datelor (Z-Score) înainte de comparație.
2. **Diferența de Viteză (Dilatarea Temporală):** Aceasta este limitarea fundamentală a Distanței Euclidiene și a Corelației Pearson. Aceste metrici sunt "rigide" temporal: ele compară punctul t_1 al seriei X strict cu punctul t_1 al seriei Y .

În realitate, crizele se desfășoară la viteze diferite. Un tipar de prăbușire care a durat 3 luni în 2008 s-ar putea repeta într-o formă accelerată (1 lună) în prezent. O metrică rigidă ar eșua în detectarea similarității din cauza nealinierii vârfurilor.

Dynamic Time Warping (DTW) soluționează această problemă fiind o metrică "elastică". Aceasta permite alinierea neliniară a seriilor, "dilatând" sau "comprimând" axa timpului pentru a găsi potrivirea morfologică optimă.

2.5.2 Formalizarea matematică a DTW

Fie două serii de timp, șablonul $T = (t_1, t_2, \dots, t_M)$ și fereastra curentă $W = (w_1, w_2, \dots, w_N)$. Scopul este găsirea unui drum de aliniere optim.

Mai întâi, construim **Matricea Costurilor Locale** $C \in \mathbb{R}^{M \times N}$, unde fiecare element (i, j) reprezintă distanța (de obicei Euclidiană pătratică) dintre punctele celor două serii:

$$C(i, j) = (t_i - w_j)^2 \quad (2.7)$$

Căutăm un **Drum de Aliniere** (Warping Path) $P = (p_1, \dots, p_K)$, unde fiecare $p_k = (i_k, j_k)$ este o pereche de indici din matricea C , care satisface condițiile de:

- *Limită:* Drumul începe în $(1, 1)$ și se termină în (M, N) .
- *Continuitate:* Pașii sunt limitați la vecini adiacenți (fără salturi).
- *Monotonie:* Indicii nu pot descresce în timp.

Distanța DTW este definită ca minimumul sumei costurilor de-a lungul tuturor drumurilor posibile. Aceasta se calculează eficient folosind programarea dinamică. Definim matricea costului acumulat γ :

$$\gamma(i, j) = C(i, j) + \min \begin{cases} \gamma(i-1, j) & (\text{insertie}) \\ \gamma(i, j-1) & (\text{\text{ștergere}}) \\ \gamma(i-1, j-1) & (\text{potrivire}) \end{cases} \quad (2.8)$$

Valoarea finală a distanței DTW este dată de $\gamma(M, N)$.

În implementarea noastră, o distanță $DTW \approx 0$ indică o potrivire structurală perfectă, iar valorile mari indică disimilaritate. Pentru a integra această metrică în sistemul de vot, transformăm distanța într-un scor de similaritate invers proporțional:

$$S_{DTW} = \frac{1}{1 + DTW(T, W)} \quad (2.9)$$

Astfel, algoritmul este capabil să recunoască semnătura unei crize chiar dacă aceasta se manifestă cu o viteză diferită față de evenimentul istoric de referință.




Figura 2.4: Rezultatele analizei DTW cu criza din 2008 ca semnatura

Capitolul 3

Arhitectura Sistemului Hibrid (Ensemble)

3.1 Pipeline-ul de Procesare

Sistemul propus integrează metodele descrise anterior într-un mecanism de vot ponderat ("Weighted Ensemble").

Algorithm 1 Pipeline Detectie Anomalii

- 1: **Input:** Seria de prețuri P_t , Șablon Criză T
- 2: **Step 1:** Extrage Trend T_{SSA} folosind SSA
- 3: **Step 2:** Calculează Reziduuri $R_t = P_t - T_{SSA}$
- 4: **Step 3:** Calibrează limite dinamice L_{GARCH} pe R_t
- 5: **Step 4:** Calibrează limite statice L_{OU} pe R_t
- 6: **Step 5:** Calculează similaritatea $S_{Pattern}$ între P_t și T
- 7: **Step 6:** Agregare Scor:

$$Scor_{Total} = w_1 \cdot I_{GARCH} + w_2 \cdot I_{OU} + w_3 \cdot I_{Pattern}$$

- 8: **Output:** Alertă dacă $Scor_{Total} > Prag_{Critic}$
-

3.2 Justificarea Ponderilor în Cadrul Ansamblului

Un aspect critic al arhitecturii propuse este mecanismul de agregare a semnalelor individuale într-un *Scor Unificat de Risc*. Deoarece metodele componente au sensibilități și rate de alarmă falsă diferite, o medie aritmetică simplă ar fi suboptimală.

Am optat pentru o schemă de ponderare ierarhică, bazată pe **specificitatea** și **severitatea** tipului de anomalie detectat de fiecare algoritm. Ponderile w_i sunt atribuite astfel:

Justificarea teoretică pentru această distribuție este următoarea:

3.2.1 1. Pondere Bazală: GARCH ($w = 1.0$)

Modelul GARCH este extrem de sensibil la fluctuațiile pieței. Deși este excelent pentru a detecta creșterea incertitudinii ("Volatility Clustering"), volatilitatea ridicată nu implică

Componentă	Pondere (w_i)	Tipul Detecției
GARCH	1.0	Reactiv (Volatilitate Locală)
Ornstein-Uhlenbeck (OU)	1.5	Statistic (Deviație de Echilibru)
Pattern Matching (DTW)	2.5	Structural (Recunoaștere Morfologică)

Tabela 3.1: Schema de Ponderare a Ansamblului Hibrid

automat o prăbușire a pieței; aceasta poate apărea și în timpul unor corecții sănătoase sau a unor știri economice minore. Fiind o metodă ****reactivă**** și cu o rată ridicată de rezultate fals-pozitive ("zgomotoasă"), îi atribuim ponderea minimă unitară. Semnalul GARCH servește drept "nivel de alertă galbenă".

3.2.2 2. Pondere Intermediară: Ornstein-Uhlenbeck ($w = 1.5$)

Procesul OU modelează proprietatea fundamentală de revenire la medie a prețurilor. O alertă din partea acestui modul indică faptul că prețul a deviat de la tendința centrală cu o magnitudine improbabilă statistic (ex: $> 3\sigma_{echilibru}$). Aceasta reprezintă o încălcare a "fizicii" normale a pieței, fiind un semnal mai puternic decât simpla volatilitate. Totuși, piețele pot rămâne iraționale pe perioade lungi (bule speculative), motiv pentru care ponderea este medie.

3.2.3 3. Pondere Critică: Pattern Matching / DTW ($w = 2.5$)

Această componentă are cea mai mare greutate în decizia finală deoarece este singura metodă ****predictivă**** și ****structurală****. Dacă algoritmul DTW identifică o similitudine morfologică ridicată (ex: $> 80\%$) cu un eveniment istoric catastrofal (precum Crash-ul din 2008 sau Martie 2020), probabilitatea unui risc sistemic este maximă. Formele grafice specifice ("signatures") ale vânzărilor în panică sunt evenimente rare și specifice. Prin urmare, o potrivire la acest nivel este considerată o alertă critică ("Black Swan"), justificând o pondere care poate declanșa singură alarma sistemului, chiar și în absența volatilității extreme inițiale.

3.2.4 Scorul Final de Anomalie

Scorul agregat la momentul t este calculat conform relației:

$$S_{ensemble}(t) = 1.0 \cdot I_{GARCH}(t) + 1.5 \cdot I_{OU}(t) + 2.5 \cdot I_{DTW}(t) \quad (3.1)$$

Unde I sunt funcții indicator binare (1 pentru detecție, 0 pentru normal). Pragul critic de acțiune este stabilit la $S_{critic} = 3.5$. Acest prag necesită consensul a cel puțin două metode (de exemplu, Volatilitate + Structură sau Statistică + Structură) pentru a valida o anomalie majoră, eliminând astfel erorile izolate ale unui singur model.





Figura 3.1: Rezultatele analizei de tip Ensemble pentru perioada 2019-2023 (Pandemie+Razboi).

Capitolul 4

Studii de Caz și Rezultate

4.1 Setul de Date

Analiza a fost efectuată pe indicele S&P 500 în perioada 2019-2024, cuprinzând evenimente majore precum Crash-ul COVID-19 (2020) și Piața Bear din 2022. De asemenea robustetea algoritmului se poate demonstra și pe alți indici bursieri.



(a) Bitcoin (BTC): Detectarea bulelor speculative

(b) Meta (META): Detectarea șocurilor idiosincratice

Figura 4.1: Validarea robusteții algoritmului pe active alternative. (a) Bitcoin prezintă o volatilitate extremă continuă, detectată corect de GARCH. (b) Meta prezintă o ruptură structurală bruscă (Gap-down) în 2022, identificată de ansamblu.

4.2 Analiza Robusteții pe Alte Clase de Active

Pentru a demonstra capacitatea de generalizare a pipeline-ului hibrid propus, am extins testarea dincolo de indicii de piață agregați (S&P 500), aplicând algoritmul pe active cu profiluri de risc distincte: criptomonede și acțiuni individuale volatile.

Așa cum este ilustrat în Figura 4.1, sistemul s-a comportat consistent în scenarii diverse:

- **Cazul Bitcoin (Fig. 4.1a):** Activul prezintă regimuri de heteroscedasticitate extremă. Componenta GARCH a ajustat dinamic pragurile, evitând generarea de alarme false continue în perioadele de volatilitate normală pentru crypto (5-10%), dar semnalând corect prăbușirile sistemice (ex: 2021, 2022).

- **Cazul Meta Platforms (Fig. 4.1b):** Analiza a evidențiat capacitatea sistemului de a gestiona șocuri idiosincratice (specifice companiei). În februarie 2022, Meta a suferit o scădere istorică de 26% într-o singură zi. Deși SSA are o inerție naturală, combinația cu detectarea volatilității instantanee a permis marcarea evenimentului ca o anomalie critică în timp real.

Aceste rezultate confirmă că arhitectura de vot ponderat (Ensemble) este robustă și nu suferă de *overfitting* pe datele indicelui S&P 500.

4.3 Analiza Comparativă: Static vs Dinamic

Comparând limitele statice derivate din procesul Ornstein-Uhlenbeck cu cele dinamice GARCH, demonstrăm că modelele statice generează alarme false în perioade de volatilitate ridicată, în timp ce abordarea hibridă reduce rata de falși pozitivi.




Figura 4.2: Rezultatele analizei OU vs GARCH cu trendul identificat SSA pentru perioada 2018-2024.

Capitolul 5

Concluzii și Direcții Viitoare

5.1 Sinteza Contribuțiilor

Prezenta lucrare a propus și validat o arhitectură hibridă pentru detectarea anomaliilor în piețele financiare, depășind limitările modelelor statistice clasice prin integrarea a trei paradigme distincte: descompunerea spectrală (SSA), fizica stocastică (Procese OU) și recunoașterea geometrică a formelor (DTW).

Principalele contribuții pot fi sintetizate astfel:

- **Unificarea Viziunii:** Tratarea anomaliilor nu doar ca deviații statistice (Outliers), ci și ca rupturi structurale de echilibru și similarități morfologice cu crize istorice.
- **Adaptabilitate:** Implementarea limitelor dinamice GARCH a demonstrat reducerea alarmelor false în regimuri de volatilitate ridicată (ex: Bitcoin), spre deosebire de pragurile statice.
- **Robustete:** Sistemul de vot ponderat (Ensemble) a permis identificarea corectă a crizelor pe clase de active diverse (S&P 500, Crypto, Tech Stocks), confirmând capacitatea de generalizare a algoritmului.

5.2 Direcții Viitoare de Cercetare

Pentru extinderea capacităților sistemului actual, se propun următoarele direcții de dezvoltare:

- **Analiza Sentimentului (NLP):** Integrarea unui modul de procesare a limbajului natural pentru analiza știrilor financiare în timp real. Acest lucru ar permite ajustarea dinamică a ponderilor ansamblului (de exemplu, creșterea ponderii GARCH în momente de incertitudine geopolitică).
- **Analiza de Rețea (Graph Theory):** Construirea unui graf de corelație între diferiți indici (Aur, Petrol, S&P 500, Bitcoin) pentru a detecta riscul sistemic prin propagarea șocurilor în rețea.
- **Optimizarea Ponderilor:** Utilizarea unui algoritm genetic sau a unei rețele neurale simple pentru a învăța automat ponderile optime (w_{SSA} , w_{GARCH} , w_{DTW}) pe baza datelor istorice, în locul setării lor euristice.

Bibliografie

- [1] Bachelier, L. (1900). *Théorie de la spéculation*. Annales Scientifiques de l'École Normale Supérieure, 3(17), 21-86. (Lucrarea fundamentală despre Random Walk/Brownian Motion).
- [2] Mandelbrot, B. (1963). *The Variation of Certain Speculative Prices*. The Journal of Business, 36(4), 394-419. (Lucrarea despre Fat Tails și respingerea normalității).
- [3] Mandelbrot, B. B. (1997). *Fractals and Scaling in Finance: Discontinuity, Concentration, Risk*. Springer Science & Business Media.
- [4] Taleb, N. N. (2007). *The Black Swan: The Impact of the Highly Improbable*. Random House. (Conceptul de Lebadă Neagră).
- [5] Golyandina, N., Nekrutkin, V., & Zhigljavsky, A. (2001). *Analysis of Time Series Structure: SSA and Related Techniques*. Chapman and Hall/CRC. (Biblia SSA-ului).
- [6] Hassani, H. (2007). *Singular Spectrum Analysis: Methodology and Comparison*. Journal of Data Science, 5(2), 239-257.
- [7] Engle, R. F. (1982). *Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation*. Econometrica, 50(4), 987-1007. (Inventatorul ARCH).
- [8] Bollerslev, T. (1986). *Generalized Autoregressive Conditional Heteroskedasticity*. Journal of Econometrics, 31(3), 307-327. (Inventatorul GARCH - esențial pentru lucrarea ta).
- [9] Uhlenbeck, G. E., & Ornstein, L. S. (1930). *On the Theory of the Brownian Motion*. Physical Review, 36(5), 823. (Originea fizică a procesului OU).
- [10] Vasicek, O. (1977). *An Equilibrium Character of the Term Structure*. Journal of Financial Economics, 5(2), 177-188. (Aplicarea OU în finanțe/dobânzi).
- [11] Sakoe, H., & Chiba, S. (1978). *Dynamic Programming Algorithm Optimization for Spoken Word Recognition*. IEEE Transactions on Acoustics, Speech, and Signal Processing, 26(1), 43-49. (Lucrarea originală care a definit DTW).
- [12] Rakthanmanon, T., et al. (2012). *Searching and Mining Trillions of Time Series Subsequences under Dynamic Time Warping*. Proceedings of the 18th ACM SIGKDD. (Despre DTW rapid pe date mari).
- [13] Chandola, V., Banerjee, A., & Kumar, V. (2009). *Anomaly Detection: A Survey*. ACM Computing Surveys, 41(3), 1-58.

- [14] Aggarwal, C. C. (2017). *Outlier Analysis* (2nd ed.). Springer International Publishing. (Referința fundamentală pentru taxonomia anomaliilor).